

초록 (Abstract)

신호등은 교통 충격파를 유발해 정체를 인접 도로망으로 전파한다. 모든 차량이 자율화·연결화된 미래에는 신호등 자체가 불필요해질 수 있다. 이 전제 아래, 본 프로젝트는 학습된 협력 주행 정책이 단일 4지 교차로에서 신호등을 대체할 수 있는지 검토한다. 자체 시뮬레이터에서 고정시간 **신호(signal)**, **규칙 기반(rule-based) 제어기**, **PPO 강화학습 에이전트**를 비교했다. 교차로 제어에서 RL 에이전트는 충돌 회피와 효율적 통행이라는 두 목표를 동시에 달성해야 하므로, 세 가지 안전 사전지식(safety prior)을 선제적으로 부여했다. 이를 통해 사실상 충돌 없이 학습이 이루어졌고, 저·중·고 교통량 조건에서 고정 신호 대비 평균 지연을 각각 80%·69%·38% 줄이고 처리량을 약 2.8–3.4배 늘리면서 모든 지표에서 규칙 기반 제어기도 넘어섰다. 이 구조에서 안전 사전지식은 충돌 없는 통행 질서를 보장하는 역할을, RL은 그 안에서 지연과 처리량을 최적화하는 역할을 각각 분담한다. 결론적으로, 신호 없는 교차로 제어에서는 안전 메커니즘과 RL의 역할 분리가 핵심이며, 둘을 결합할 때 비로소 안전성과 효율성을 함께 달성할 수 있다.

1. 서론 (Introduction)

신호등 교차로는 상충하는 차량 흐름을 시간적으로 분리하는 시간 분할 방식의 제어 방식이다. 이 방식은 충돌 가능성을 구조적으로 낮춘다는 장점이 있지만, 고정된 신호 주기에 의존하기 때문에 비효율을 동반한다. 교차 교통이 없는 상황에서도 차량은 적색 신호에서 정지해야 하며, 이후 대기과 재가속을 반복한다. 이 과정에서 대기열이 형성되고 통행 시간이 증가한다. 또한 한 교차로에서 발생한 지연은 해당 지점에만 머무르지 않고, 상류 도로와 인접 교차로로 전파되어 도로망 전체의 정체로 이어질 수 있다.

신호 제어의 한계는 세 가지로 요약된다. 첫째, **정지-출발의 불연속성**이다. 불필요한 정지와 재출발이 반복되며 차량 흐름이 끊긴다. 둘째, **공간적 파급**이다. 한 교차로의 지연이 주변 도로망으로 확산된다. 셋째, **경직성**이다. 고정된 신호 주기는 실시간 교통 수요 변화에 유연하게 대응하지 못한다.

모든 차량이 자율주행 차량이고 주변 상황을 관측할 수 있다면, 이러한 제약은 완화될 수 있다. 차량들은 고정된 신호에 따라 번갈아 통과하는 대신, 교차로 진입 시점과 속도를 조정하며 서로의 통행을 협상할 수 있다. 즉, 완전히 멈추지 않고 필요한 만큼만 감속한 뒤 교차 교통과 엇갈려 통과하는 방식이 가능하다. 이것이 **협력적 신호 없는 교차로 제어**의 핵심 아이디어이다.

강화학습은 이 문제에 적합한 접근법으로 볼 수 있다. 교차로 통과는 차량이 매 순간 가속도와 감속도를 선택해야 하는 순차 의사결정 문제이며, 현재의 행동이 이후의 교통 흐름과 안전성에 영향을 미치기 때문이다. 그러나 강화학습 기반 제어에서는 안전성이 자동으로 보장되지 않는다. 신호등은 충돌 가능성을 구조적으로 차단하지만, RL 에이전트는 보상 함수가 안전한 행동을 충분히 유도할 때에만 안전하게 작동한다. 특히 안전성과 효율성 사이의 균형을 보상 설계만으로 안정적으로 맞추는 것은 매우 취약한 문제이다.

- **통제된 비교 연구:** 자체 제작한 교차로 시뮬레이터를 사용하여 세 가지 교통량 밀도 조건에서 신호 제어, 규칙 기반 제어, 강화학습 기반 제어를 비교한다.
- **순수 강화학습 실패原因的 진단:** 충돌 페널티와 도착 보너스의 비율을 스윙하여, 안전성과 효율성을 동시에 확보할 수 있는 보상 구간이 좁고 교통량 밀도에 따라 최적값이 변동함을 보인다. 이는 보상 설계만으로는 다양한 교통 조건에 일반화되는 안전한 정책을 얻기 어렵다는 점을 보인다.
- **안전 사전지식을 결합한 제어 설계:** 규칙 기반 사전지식, 행동 복제를 통한 웜스타트, 실행 시점의 안전 실드를 결합함으로써 보상 설계의 취약성을 우회하고, 충돌 없이 높은 처리량을 달성하는 제어기를 구성한다.
- **안전성의 출처를 분리하는 제거 실험:** 평가 시점에 안전 실드를 제거했을 때 학습된 정책이 모든 에피소드에서 충돌함을 보인다. 이는 최종 시스템에서 강화학습 정책이 주로 효율성을 담당하는 반면, 안전성은 사전지식과 실행 시점 안전 장치에 의해 제공됨을 보여준다.

2. 배경 및 관련 연구 (Background and Related Work)

기존 연구는 대체로 신호등 체계를 유지한 채 이를 더 지능적으로 제어하는 방향에 집중해 왔다. SCATS와 SCOOT 같은 반응형 신호 제어 시스템은 실시간 교통 수요에 따라 신호 주기를 조정하며, IntelliLight와 PressLight는 강화학습을 이용해 현시 전환 시점을 최적화한다 [Wei et al., 2018, 2019]. 즉, 이들 연구는 **신호 현시 구조를 전제로 하여 언제 전환할 것인가**를 다룬다. 반면 본 연구는 모든 차량이 자율주행 차량이라는 조건에서 **현시 구조 자체를 제거할 수 있는가**를 탐구한다.

본 연구의 안전 사전지식은 행동 복제와 안전 강화학습에 기반한다. 행동 복제는 전문가 시연을 지도학습 방식으로 모방하는 방법으로 [Pomerleau, 1988], 본 연구에서는 규칙 기반 제어기의 데이터를 이용해 RL 정책을 웜스타트하는 데 사용한다. 또한 실딩은 정책이 선택한 행동을 실행 전에 검사하고, 위험한 행동을 안전한 행동으로 대체하는 실행 시점 안전 필터이다 [García and Fernández, 2015; Alshiekh et al., 2018]. 여기에 교통량 밀도를 단계적으로 높이는 커리큘럼 학습을 결합하여 학습 안정성을 높인다 [Bengio et al., 2009]. 규칙 기반 제어기의 차량 추종은 IDM의 원리를 참고했으며 [Treiber et al., 2000], 전체 문제 설정은 highway-env와 같은 자율주행 의사결정 환경의 구성을 따른다 [Leurent, 2018].

3. 문제 정식화 (Problem Formulation)

3.1 시뮬레이션 환경

본 프로젝트에서는 외부 교통 시뮬레이터에 의존하지 않고, 단일 4지 교차로를 자체 구현하였다. 교차로는 네 방향(N, E, S, W)의 진입로로 구성되며, 각 방향은 진입 차로 1개와 진출 차로 1개를 갖는 왕복 2차로 우측통행 도로로 설정하였다. 차량은 각 진입 차로에서 생성되어 직진, 좌회전, 우회전 중 하나의 경로를 따라 이동한다. 각 경로는 진입 정지선과 대응되는 진출 차로를 연결하며, 회전 경로는 2차 베지어 곡선으로 부드럽게 구성하였다. 차량은 진출 도로 끝에 도달하면 시뮬레이션에서 제거된다. 차량은 방향을 갖는 직사각형으로 모델링하고, 충돌은 분리축 정리(Separating Axis Theorem, SAT)를 이용한 회전 직사각형 겹침 검사로 판정하였다. 충돌이 발생하면 에피소드는 즉시 종료되므로, 본 환경에서 안전성은 드물지만 치명적인 사건으로 다루어진다. 교통 수요는 포아송 도착 과정에 가깝게 생성하였다. 매 스텝 각 진입로에서 $rate \cdot dt$ 의 확률로 차량이 생성되며, 진입로별 도착률은 저밀도, 중밀도, 고밀도 조건에서 각각 0.030 / 0.065 / 0.105 대·s⁻¹로 설정하였다. 진행 방향 비율은 직진 56%, 우회전 24%, 좌회전 20%이다. 세부 설정은 부록 A에 제시하였다.

3.2 세 가지 제어기

- **신호등(Signal, 베이스라인).** 신호 제어기는 전통적인 4현시 고정시간 신호를 기준으로 사용한다. 신호 주기는 NS 보호 좌회전 15초, 황색 3초, NS 직진 및 우회전 30초, 황색 3초, 전적색 2초, 그리고 이에 대응되는 EW 현시로 구성되며 전체 주기는 106초이다. 차량은 적색, 황색, 보호 좌회전 상충 상황에서 제동한다.
- **규칙(Rule, 협력형, 신호 없음).** 규칙 기반 제어기는 신호등 없이 차량 간 협력 규칙으로 교차로를 통과하도록 설계하였다. 각 차량은 앞차와 최소 간격을 유지하고, 교차로 내부에서 다른 차량과의 기하학적 상충을 판단한다. 상충이 발생하면 이미 교차로 안에 있는 차량, 중심에 더 가까운 차량, 우측 차량, 더 오래 기다린 차량 순으로 우선권을 부여한다. 이 제어기는 수작업 기준선이자 RL 정책의 행동 복제 학습을 위한 교사로 사용된다.
- **RL(PPO).** 강화학습 제어기는 PPO 기반의 분산형 에이전트로 구성하였다. 모든 활성 차량은 동일한 정책 네트워크를 공유하며, 각 차량은 자신의 국소 관측을 바탕으로 감속, 유지, 가속 중 하나를 선택한다. 이를 통해 중앙 신호 계획 없이 개별 차량의 의사결정으로 교차로 통과를 조정한다.

3.3 마르코프 결정 과정 (MDP)

우리는 각 차량의 제어를 공유 정책을 갖는 분산형 부분관측 MDP로 정식화한다.

관측(Observation): 각 차량의 관측은 54차원의 정규화된 특징 벡터로 구성된다. 여기에는 차량 자신의 위치, 진행 방향, 속도, 정지선까지의 거리, 교차로 중심까지의 거리, 남은 경로 비율, 교차로 내부 여부, 시간 관련 특징이 포함된다. 또한 진입 방향 4개, 진출 방향 4개, 회전 유형 3개를 원-핫 인코딩으로 표현한다. 주변 교통 상황을 반영하기 위해 앞차의 상대 거리, 상대 속도, 접근율(closing rate), 진입로별 접근 밀도 4개, 그리고 가장 가까운 이웃 차량 5대의 상대 위치, 속도, 거리 정보를 포함한다. 이웃 차량 및 앞차 정보는 분산형 에이전트가 상충 구역을 공유하는 차량들을 인식하고, 협력적인 통과 전략을 학습할 수 있도록 한다. 세부 항목은 부록C에 제시한다.

행동(Action): 행동 공간은 감속($-2.0 \text{ m}\cdot\text{s}^{-2}$), 유지, 가속($+0.85 \text{ m}\cdot\text{s}^{-2}$)의 세 가지 이산 종방향 행동으로 구성된다. 차량은 사전에 정의된 경로를 따르므로, 제어는 종방향 가속도 선택으로 제한된다. 이를 통해 행동 공간을 단순화하고, 신호 제어 및 규칙 기반 제어와의 비교를 명확하게 할 수 있다.

보상(Reward): 전체 보상 함수는 시간 페널티, 진행 보상, 저속 및 대기 페널티, 위험 근접 페널티 등으로 구성되며, 세부 항목은 부록D에 제시한다. 도착 보너스는 차량이 교차로를 통과해 진출 도로의 끝에 도달했을 때 부여되는 양의 보상이다. 이는 에이전트가 단순히 멈춰서 충돌을 피하는 정책을 선택하지 않고, 교차로를 빠르게 통과하도록 유도한다. 반대로 충돌 페널티는 차량 간 충돌이 발생했을 때 부여되는 큰 음의 보상이며, 충돌이 발생하면 에피소드는 즉시 종료된다. 따라서 충돌은 단순한 성능 저하가 아니라, 정책이 반드시 회피해야 하는 실패 사건으로 취급된다.

이 두 항의 상대적 크기, 즉 **보상 비율(reward ratio) = 충돌 페널티 / 도착 보너스**는 RL 정책의 행동을 결정하는 핵심 설계 변수이다. 본 실험의 기본 설정에서는 도착 보너스를 +9.5, 충돌 페널티를 -35.0으로 두어 보상 비율을 약 3.7로 설정하였다. 이 비율이 너무 낮으면 에이전트는 빠른 통과를 위해 위험한 행동을 감수하고, 너무 높으면 충돌을 피하기 위해 지나치게 보수적으로 행동한다. 따라서 이 비율은 안전성과 효율성 사이의 균형을 조절하는 가장 중요한 보상 설계 요소이며, 6.2절에서 이에 대한 민감도 분석을 수행한다.

4. 방법: RL을 위한 안전 사전지식 (Methods: A Safety Prior for RL)

앞서 정의한 보상만으로 PPO 에이전트를 처음부터 학습시키면 안정적인 정책을 얻기 어렵다. 순수 PPO는 충돌 페널티와 도착 보너스의 균형에 매우 민감하며 조건이 바뀌면 쉽게 실패한다. 본 연구는 에이전트가 드문 충돌 경험만으로 안전한 주행 전략을 발견하도록 두지 않고, **안전 사전지식**을 세 단계로 주입한다.

4.1 규칙 기반 안전 사전지식

규칙 기반 제어기는 사람이 설계한 안전 주행 원칙을 명시적으로 포함한다. 구체적으로 앞차와의 안전 시간 간격 유지, 경로 간 기하학적 상충 감지, 그리고 우선순위가 낮은 차량의 양보 규칙을 사용한다. 이 제어기는 단순한 비교 기준선이 아니라, 이후 행동 복제와 안전 실드를 통해 RL 정책에 전달되는 안전 행동의 원천으로 사용된다.


4.2 행동 복제 워밍스타트 (Behavior-cloning warm start)

RL 학습에 앞서, 규칙 기반 제어기를 세 가지 교통량 조건에서 실행하여 약 6,000개의 관측-행동 쌍을 수집하였다. 이후 정책 네트워크가 이 행동을 모방하도록 교차 엔트로피 손실로 4 에폭 동안 지도학습하였다. 이 과정은 정책이 무작위 상태에서 출발하는 대신, 기본적인 안전 주행 패턴을 갖춘 상태에서 PPO 학습을 시작하도록 하기 위한 것이다. 이를 통해 RL이 충돌 경험만으로 안전 행동을 처음부터 탐색해야 하는 부담을 줄이고, 이후 학습이 교차로 통과 효율을 개선하는 데 집중할 수 있도록 한다.

4.3 실행 시점 안전 실드를 갖춘 PPO 미세조정

행동 복제 이후에는 PPO로 정책을 미세조정한다. 이때 액터와 환경 사이에 **안전 실드(safety shield)**를 두어, 정책이 제안한 행동을 실행 전에 검사한다. 앞차와의 시간 간격을 위반하거나, 우선순위가 높은 상충 차량에 양보하지 않는 행동은 안전하지 않은 것으로 판단하고, 감속 또는 유지 행동으로 대체한다.

에이전트는 실드가 적용된 실제 실행 행동을 바탕으로 학습한다. 따라서 정책은 위험한 행동을 반복하기보다, 실드가 허용하는 안전한 행동을 선택하도록 조정된다. 또한 학습 안정성을 높이기 위해 교통 수요를 저밀도에서 중밀도, 고밀도로 높이는 80 에피소드 커리큘럼을 사용하였다.



안전 실드를 갖춘 PPO: 액터가 행동을 제안하고, 실드가 안전하지 않은 행동을 거르며, 크리티크가 가치를 추정하고, 보상이 네트워크를 갱신한다.

5. 실험 설정 (Experimental Setup)

PPO 에이전트는 교통량 커리큘럼에 따라 **80개 에피소드** 동안 학습하였다. 이후 고정시간 신호, 규칙 기반 제어기, PPO 제어기를 **저·중·고 교통량**에서 평가하고, 각 조건은 **3개 무작위 시드**의 220초 결과로 평균하였다. 지표는 **차량당 평균 대기 시간, 평균 지연, 처리량, 평균 대기열 길이, 완주율, 충돌률**이며, 지연 감소율은 동일 교통량의 고정 신호 대비로 계산하였다. 추가로 순수 RL의 **보상 비율 스윙**과 평가 시점의 **실드 켜기/끄기 제거 실험(부록 E)**을 수행하였다. 모든 제어기는 동일한 수요 시드를 사용하므로 성능 차이는 교통 수요가 아니라 제어 방식에서 비롯된다.

6. 결과 (Results)

6.1 주 비교: RL이 모든 밀도에서 두 베이스라인을 능가

그림 1은 세 시드 평균 평가 결과를 요약한다. 자세한 수치는 부록 E의 표 1에 제시하였다. PPO는 모든 교통량 수준에서 평균 대기 시간, 지연, 처리량, 완주율 측면에서 고정 신호와 규칙 기반 제어를 능가했으며, 충돌은 발생하지 않았다. 유일한 예외는 평균 대기열 길이로, 이 지표에서는 규칙 기반 제어가 PPO보다 약간 낮았다.




그림 1: 제어기 및 교통량 수준별 평균 대기 시간 및 제어기 및 교통량 수준별 처리량.


고정 신호 대비 PPO는 평균 지연을 저밀도, 중밀도, 고밀도에서 각각 80%, 69%, 38% 줄였다. 규칙 기반 제어기의 지연 감소율은 각각 57%, 47%, 23%였다. 이는 각 제어 방식의 작동 방식과 일치한다. 고정 신호는 교차로가 비어 있어도 차량의 완전 정지를 강제하므로, 차량은 긴 대기 시간과 해소되지 않는 대기열을 겪는다. 반면 신호 없는 제어기들은 속도를 조절하며 교차 교통 사이에 끼어들어 통과하므로, 불필요한 정지를 크게 줄인다.

PPO가 규칙 기반 제어기보다 우수한 이유는 단순히 현재의 상충 상황에 반응하는 데 그치지 않고, **가치 함수를 통해 이후의 교통 흐름까지 고려하기** 때문이다. 그 결과 PPO는 더 부드럽게 감속하고, 빈틈에 맞춰 교차로에 진입하는 전략을 학습한다. 개선 폭은 최적화 여지가 큰 저밀도와 중밀도에서 가장 크고, 물리적 용량 제약이 강해지는 고밀도에서는 줄어든다. PPO는 평균 대기 시간을 신호 제어 대비 크게 낮추는 동시에, 처리량을 약 2.8배, 2.9배, 3.4배로 증가시켰다.

표 1을 해석할 때는 두 가지 점에 유의해야 한다. 첫째, **규칙 기반 제어기는 모든 밀도에서 PPO보다 약간 짧은 평균 대기열을 보인다**. 예를 들어 고밀도 조건에서 규칙 기반 제어기의 평균 대기열은 1.74대, PPO는 2.88대이다. 그러나 이는 PPO의 성능 저하라기보다, 더 많은 차량이 교차로 접근과 통과를 시도한 결과로 해석해야 한다. PPO는 약간 더 긴 대기열을 허용하는 대신 더 높은 처리량과 완주율을 달성한다. 둘째, **고정 신호의 차량당 대기 시간과 지연은 수요에 대해 비단조적으로 나타난다**. 예를 들어 고밀도 조건의 평균 대기 시간은 36.9초로, 중밀도 조건의 46.4초보다 낮다. 이는 고수요에서 신호 제어가 심하게 포화되어 더 적은 차량만 완주했기 때문에 발생한 편향이다. 따라서 고밀도에서의 38% 지연 감소는 낮게 편향된 신호 베이스라인을 기준으로 한 값이며, 신호 제어의 처리량 붕괴와 함께 해석해야 한다.

6.2 순수 RL이 충분하지 않은 이유: 보상 비율 민감도

안전 사전지식을 도입하기에 앞서, 보상 설계만으로 순수 PPO 에이전트가 안전하고 효율적인 정책을 학습할 수 있는지 확인하였다. 이를 위해 실드와 웜스타트를 제거한 순수 PPO를 사용하고, **보상 비율 = 충돌 페널티 / 도착 보너스를 0.5에서 20까지 변화**시키며 각 설정마다 에이전트를 새로 학습하였다. 이후 충돌률과 완주율을 측정하였다. 각 그림에서 x축은 보상 비율이며, 빨간 곡선은 충돌률, 파란 곡선은 완주율을 나타낸다.



실험 결과, 순수 PPO 에이전트는 두 가지 실패 모드 사이에서 쉽게 불안정해짐을 보여준다.


- **비율이 너무 작음** → 도착 보너스가 지배하여 에이전트가 공격적으로 주행하다 **충돌**한다: 빨간 충돌률 곡선은 비율 0.5에서 저 교통량 0.55, 고 교통량 **0.82**에 이른다. 충돌이 에피소드를 끝내므로 완주율은 매우 낮게 유지된다.
- **비율이 너무 큼** → 충돌 페널티가 지배하여 에이전트가 너무 조심스러워진 나머지 **교차로 앞에서 멈춰 결코 진입하지 않는다**; 파란 완주율 곡선은 저 교통량 비율 20에서 0.08까지 붕괴한다.

가장 중요한 관찰은 완주율이 최대가 되는 보상 비율이 교통량 밀도에 따라 달라진다는 점이다. 저밀도 조건에서는 완주율이 비율 약 3.7 근처에서 가장 높지만, 고밀도 조건에서는 약 1.5 근처에서 정점을 보이며, 그때의 완주율 자체도 훨씬 낮다. 즉, 안전성과 효율성을 동시에 확보할 수 있는 보상 구간은 좁고, 그 위치도 교통량에 따라 이동한다.

이는 보상 설계만으로 모든 교통 조건에 일반화되는 안전한 정책을 얻기 어렵다는 핵심적인 실증 근거이다. 실제 교차로 제어기는 다양한 밀도의 교통 상황을 동시에 마주하므로, 모든 조건에서 안정적으로 작동하는 단일 보상 비율을 기대하기 어렵다. 본 연구에서 사용한 기본 비율 3.7은 저밀도 조건의 최적점에 가깝지만, 최종 에이전트의 견고성은 이 값 자체가 아니라 **규칙 기반 사전지식, 행동 복제 웜스타트, 실행 시점 안전 실드**의 결합에서 나온다.

6.3 안전 사전지식은 충돌 없이 학습된다

안전 사전지식을 도입한 이후 학습은 안정적으로 진행되었으며, 충돌은 거의 발생하지 않았다. 전체 80개 학습 에피소드 중 충돌은 단 한 번, 저밀도 조건의 에피소드 12에서만 발생하였다. 이는 앞선 순수 RL 스왑에서 관찰된 빈번한 충돌과 뚜렷하게 대비된다. 행동 복제 초기화와 안전 실드는 학습 초기부터 에이전트가 위험한 상태공간에 진입하지 않도록 제한한다. 학습 과정에서도 정책은 점진적으로 안정화되었다. 평균 스텝 보상은 -0.020 에서 양수로 상승했으며, 정책 엔트로피는 약 0.92에서 0.13으로 감소하였다. 이는 정책이 초기의 불확실한 행동 분포에서 점차 더 확정적인 선택으로 수렴했음을 의미한다. 또한 커리큘럼에 따라 교통 수요가 증가하면서 완주 차량 수도 함께 증가하였다. 따라서 본 방법에서 안전성은 학습 후반에 뒤늦게 획득되는 성질이 아니라, 행동 복제와 안전 실드를 통해 학습 초기부터 주입되는 구조적 특성이다. 이는 실제 배치 가능한 교차로 제어 시스템에 특히 중요한 조건이다.



PPO 학습 곡선: 80 에피소드 커리큘럼에 걸친 **평균 스텝 보상, 평균 지연, 완주 차량, 충돌 차량**.

7. 논의 (Discussion)

기대한 것 대 발견한 것. 우리는 RL이 고정 신호를 이길 것으로 기대하였고 실제로 이겼다. 우리가 예상하지 못한 것은 그 결과에 이르는 경로가 얼마나 취약한가였다. 보상 비율 스왑(6.2절)은 “충돌을 그냥 세계 페널티하면 된다”는 직관이 역효과를 낼을 보여준다: 페널티를 너무 높이면 에이전트가 교착되고, 너무 낮추면 충돌하며, 올바른 설정은 교통량 밀도에 따라 바뀐다. 새롭게 알게된 사실은, 안전이 중요한 제어 문제에서 RL의 어려운 부분은 최적화가 아니라 **성능을 파괴하지 않으면서 안전을 명세하는 것**이며, 이것이 스칼라 조정보다 구조(실드, 사전지식)로 더 잘 해결된다는 점이다.

한계. (1) 단일 교차로를 연구하였고, 동기로 인용한 도로망 단위 파급은 직접 측정하지 않았다. (2) 시뮬레이터는 완벽한 관측과 즉각적이고 잡음 없는 이웃 상태 통신을 가정한다 — 실제 배치는 센싱 잡음, 지연, 비협조적(인간) 운전자를 마주한다.

8. 결론 (Conclusion)

우리는 강화학습이 완전 자율주행 교차로에서 신호등을 대체할 수 있는지 물었다. 답은 조건부 **예**: PPO 에이전트는 고정 신호 대비 지연을 최대 80% 줄이고 처리량을 대략 3배로 높이며, 강력한 규칙 기반 제어기조차 능가한다 — 단, **안전 사전지식**이 주어질 때에만 그렇다. 순수 보상 설계에 맡겨두면 RL은 충돌과 동결 사이의 좁고 밀도 의존적인 작동 구간을 가진 취약한 존재다. 여기서 알 수 있는 실용적 방법론이 우리가 가장 강조하고 싶은 기여다: **RL에게 안전을 처음부터 학습하라고 요구하지 말고, 행동 복제 출발점과 실행 시점 안전 실드 위에 얹고, RL이 실제로 잘하는 것 ‘효율성’을 학습하게 해야한다.**

참고문헌 (References)

- Alshiekh, M., Bloem, R., Ehlers, R., Könighofer, B., Niekum, S., & Topcu, U. (2018). *Safe Reinforcement Learning via Shielding*. AAAI.
- Bengio, Y., Louradour, J., Collobert, R., & Weston, J. (2009). *Curriculum Learning*. ICML.
- García, J., & Fernández, F. (2015). *A Comprehensive Survey on Safe Reinforcement Learning*. JMLR, 16, 1437–1480.
- Gupta, J. K., Egorov, M., & Kochenderfer, M. (2017). *Cooperative Multi-Agent Control Using Deep Reinforcement Learning*. AAMAS Workshop.
- Leurent, E. (2018). *An Environment for Autonomous Driving Decision-Making*. GitHub: github.com/eleurent/highway-env.
- Pomerleau, D. A. (1988). *ALVINN: An Autonomous Land Vehicle in a Neural Network*. NeurIPS.
- Treiber, M., Hennecke, A., & Helbing, D. (2000). *Congested Traffic States in Empirical Observations and Microscopic Simulations*. Physical Review E, 62(2), 1805.
- Wei, H., Zheng, G., Yao, H., & Li, Z. (2018). *IntelliLight: A Reinforcement Learning Approach for Intelligent Traffic Light Control*. KDD.
- Wei, H., et al. (2019). *PressLight: Learning Max Pressure Control for Signalized Intersections*. KDD.

부록 A. 시뮬레이션 설정 (Simulation Configuration)

파라미터	값	파라미터	값
시간 스텝 dt	0.20 s	최고 속도	5.4 m·s ⁻¹ (≈19 km/h)
도로 길이(진입로당)	86 m	차량 크기	7.8 m × 3.0 m
교차로 반폭	17 m	최소 추종 간격	8.0 m
차로 폭	6.2 m	시간 간격(headway)	1.25 s
감속 / 유지 / 가속	-2.0 / 0 / +0.85 m·s ⁻²	평가 구간	220 s
도착률(저/중/고)	0.030 / 0.065 / 0.105 대·s ⁻¹	회전 비율(직진/우/좌)	0.56 / 0.24 / 0.20
신호 주기	106 s (보호좌 15 s, 직진 30 s, 황색 3 s, 전적색 2 s)	충돌 판정	OBB 겹침 (SAT)

부록 B. PPO 및 학습 설정 (PPO and Training Configuration)

하이퍼파라미터	값	하이퍼파라미터	값
네트워크	MLP 54→160→160→80	할인율 γ	0.992
활성화 함수	LayerNorm + Tanh	GAE λ	0.94
헤드	정책 / 가치 분리	클립 ϵ	0.20
옵티마이저	Adam, lr 3×10^{-4}	가치 계수	0.55
갱신당 PPO 에폭	5	엔트로피 계수	0.018
배치 크기	1024	그래디언트 노름 클립	0.8
학습 에피소드	80 (커리큘럼 저→중→고)	평가 시드	3
BC 웜스타트	약 6,000 샘플, 4 에폭, CE 손실	행동 공간	3 (감속/유지/가속)

부록 C. 관측 벡터 (54차원)

블록	차원	내용
자차 운동학	11	위치(x,y), 진행방향(dx,dy), 속도, 정지선까지 거리, 중심까지 거리, 남은 비율, 교차로 내부 플래그, 생존 시간, 에피소드 진행 위상
경로 인코딩	11	원-핫 진입(4), 진출(4), 회전(3)
앞차	3	정규화 간격, 앞차 속도, 접근율(closing rate)
접근 밀도	4	진입로별 대기열 밀도
가장 가까운 이웃 5대	25	각 차량당 상대 위치(2), 상대 속도(2), 거리(1)

부록 D. 보상 설정

구성 요소	값	목적
시간 페널티	-0.010 / 스텝	완주 유도
진행 보상	+0.030 · (Δs / 최대 스텝 거리)	전진 보상
저속 세이핑	-0.003 · (1 - v/v_{max})	느장 억제
제동 페널티	-0.010 (속도 중 감속 시)	불필요한 제동 억제
대기 페널티	-0.020 (거의 정지 시)	대기열 형성 억제
위험 근접(near-miss)	근접 교차 조우 당 -0.05	위험한 끼어들기 억제
도착 보너스	+9.5	진출 도달 보상
충돌 페널티	-35.0 + 에피소드 종료	안전 신호

부록 E.

교통량	제어기	대기(s) ↓	지연(s) ↓	처리량(대/h) ↑	대기열 ↓	완주율 ↑	충돌률
저	신호등	26.5	39.9	98	3.72	0.33	0.00
저	규칙	5.6	17.2	207	0.46	0.65	0.00
저	PPO	4.4	7.9	278	0.59	0.74	0.00
중	신호등	46.4	62.9	142	5.23	0.38	0.00
중	규칙	17.4	33.4	360	1.49	0.69	0.00
중	PPO	11.9	19.8	415	1.81	0.70	0.00
고	신호등	36.9	51.4	125	5.47	0.35	0.00
고	규칙	23.1	39.5	322	1.74	0.63	0.00
고	PPO	19.6	32.0	420	2.88	0.69	0.00

표 1. 주 결과(3 시드 평균, 220 s 구간).

부록 F. 안전성은 어디에서 오는가? 실드 제거 실험

표 1에서 PPO 제어기는 모든 교통량 조건에서 충돌 0을 기록하였다. 그러나 이 결과만으로 학습된 정책 자체가 충돌 회피 능력을 내재화했다고 판단하기는 어렵다. 충돌이 발생하지 않은 원인이 정책의 학습 결과인지, 실행 시점에 적용된 안전 실드의 개입 때문인지를 분리하여 확인할 필요가 있다. 이를 위해 본 연구에서는 별도의 제거 실험을 수행하였다. 실드를 활성화한 상태에서 하나의 정책을 학습시킨 뒤, 동일한 정책을 평가 시점에서 실드 켜기와 실드 끄기 조건으로 각각 평가하였다.

교통량	평가 모드	충돌률 ↓	충돌로 종료된 에피소드 비율	완주율 ↑	지연(s) ↓
저	실드 ON	0.00	0.0	0.68	8.0
저	실드 OFF	0.38	1.0	0.06	—
중	실드 ON	0.00	0.0	0.52	5.0
중	실드 OFF	0.27	1.0	0.22	—
고	실드 ON	0.00	0.0	0.51	26.0
고	실드 OFF	0.26	1.0	0.14	—

표 2. 실드 제거 실험(동일 정책을 실드 켜기/끄기로 평가; 별도 실행, 3 시드 평균).

제거 실험 결과, 실드를 제거한 경우 모든 교통량 조건에서 모든 평가 에피소드가 충돌로 종료되었다. 충돌로 종료된 에피소드 비율은 저·중·고 교통량 모두에서 1.0이었다. 충돌 발생 전까지 완주한 차량의 비율도 제한적이었다. 완주율은 저 교통량에서 6%, 중 교통량에서 22%, 고 교통량에서 14%에 그쳤다. 이는 학습된 에이전트가 충돌 회피를 충분히 내재화하지 못했음을 보여준다. 다시 말해, 에이전트는 독립적으로 안전을 보장하는 정책을 학습한 것이 아니라, 안전 실드가 강제하는 허용 영역 안에서 지연과 처리량을 개선하는 방식으로 학습하였다. 따라서 PPO 제어기가 충돌 없이 작동한다는 표 1의 결과는 안전 사전지식과 실행 시점의 안전 실드가 결합된 조건에서 해석되어야 한다.